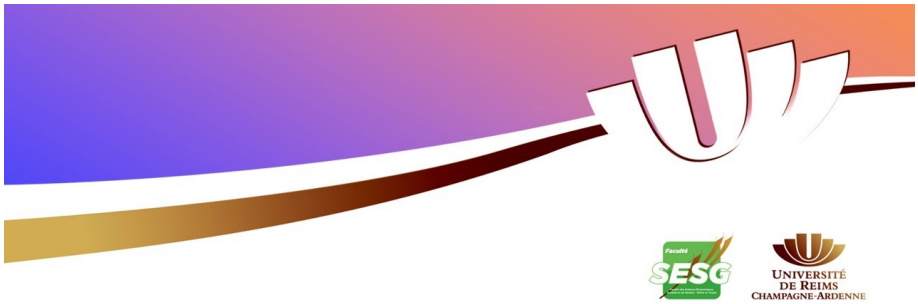


Rapport de projet

valant évaluation dans le cadre de :
Diplôme : À compléter
Année universitaire : 2026-2027
Module d'enseignement : Apprentissage non supervisé
Responsable : Frédéric Blanchard, Philippe Regnault
Comptant pour : À compléter

L'algorithme Affinity Propagation

Hervé ADJAKOSSA & Marie DE AMORIM PEREIRA DA SILVA

Métriques

Finalisé le : 2026-11-10
Page(s) : 5
Références(s) : –
Figure(s) : –
Table(s) : –
Théorème(s) : 0

Résumé :

Mots-clés :

Matériel supplémentaire :
git : https ://gitlab-mi.univ-reims.fr/dea0014/affinity_propagation
:

Table des matières

1 INTRODUCTION **3**

2 I. POSITIONNEMENT DE L'ALGORITHME AFFINITY PROPAGATION DANS L'APPRENTISSAGE AUTOMATIQUE **4**

2.1 A. La classification non supervisée : le clustering 4

2.2 B. Les principales familles de méthodes de clustering 4

2.3 C. La place de l'Affinity Propagation 4

Bibliographie **5**

1. INTRODUCTION

Dans le cadre de la matière apprentissage non supervisé, enseignée par Monsieur Frédéric BLANCHARD et Monsieur Philippe REGNAULT, nous étudions l'algorithme "Affinity Propagation".

Pour commencer, il semble important d'établir une première distinction entre l'apprentissage supervisé et non supervisé. L'apprentissage non-supervisé, aussi appelé apprentissage automatique, consiste à utiliser des algorithmes pour apprendre des structures, des relations ou des règles à partir de données. Au lieu de programmer manuellement toutes les règles que l'ordinateur doit suivre, on lui fournit des données et une méthode qui lui permet d'en extraire certaines informations. L'apprentissage supervisé en revenche, consiste à utiliser des algorithmes pour apprendre des relations entre des données et des résultats connus, afin de prédire ces résultats pour de nouvelles observations. La différence majeure réside donc dans la connaissance (ou non) du résultat à prédire sur les données d'entraînement. Ce projet s'inscrit donc dans une démarche d'apprentissage non-supervisé.

Le terme d'algorithme a été mentionné à plusieurs reprises, il nous semble donc important de commencer par le définir. Un algorithme est un processus systématique de résolution d'un problème. Un algorithme d'apprentissage automatique est plus élaboré : il utilise les données pour construire une solution à un problème donné. Il existe de nombreuses méthodes, car tous les problèmes ne se ressemblent pas. Certaines méthodes cherchent à prédire une valeur, d'autres à classer des observations, d'autres encore à découvrir des groupes ou des relations cachées dans les données.

Nous nous intéresserons donc, dans ce rapport, à l'algorithme "Affinity Propagation". Notre travail permettra donc notamment de comprendre le but de cet algorithme, le comparer à d'autres algorithmes ayant un but similaire afin d'identifier les situations les plus propices à son utilisation, puis de comprendre les fondements mathématiques sous-jacents. Finalement, nous préciserons une implémentation existante sour R avant de mettre en place une application permettant de se familiariser avec Affinity Propagation.

2. I. POSITIONNEMENT DE L'ALGORITHME AFFINITY PROPAGATION DANS L'APPRENTISSAGE AUTOMATIQUE

2.1. A. La classification non supervisée : le clustering

L'apprentissage non supervisé regroupe plusieurs familles de méthodes ayant pour objectif d'extraire des informations à partir de données non étiquetées. Parmi celles-ci, le *clustering*, également appelé classification non supervisée, consiste à répartir les observations d'un jeu de données en plusieurs groupes, appelés clusters.

L'objectif est de réunir au sein d'un même groupe les observations présentant des caractéristiques similaires, tout en distinguant autant que possible les observations appartenant à des groupes différents. Contrairement à la classification supervisée, les groupes ne sont pas définis à l'avance. L'algorithme doit donc identifier lui-même une organisation pertinente des données, à partir des informations dont il dispose.

Le clustering peut répondre à différents objectifs, notamment identifier des profils similaires au sein d'une population, regrouper des individus présentant des caractéristiques communes ou encore découvrir des structures dans des données complexes.

Il existe cependant plusieurs manières de construire ces groupes. Les méthodes de clustering se distinguent notamment par la façon dont elles mesurent les ressemblances entre observations et par les règles utilisées pour former les groupes.

2.2. B. Les principales familles de méthodes de clustering

Il existe différentes approches pour réaliser une classification non supervisée. Parmi les plus connues, on peut notamment distinguer les méthodes de partitionnement, les méthodes hiérarchiques et les méthodes fondées sur la densité.

Concernant les méthodes de partitionnement,elles cherchent à répartir directement les observations en un nombre déterminé de groupes. L'algorithme K-means en est un exemple classique. Il consiste à attribuer chaque observation au centre de groupe le plus proche, puis à actualiser ces centres jusqu'à obtenir une certaine stabilité. Cette approche nécessite généralement de définir le nombre de groupes souhaité avant de lancer l'algorithme. On verra donc qu'Affinity Propagation est un algorithme particulier de cette famille.

Les méthodes hiérarchiques quant à elles construisent une organisation des observations sous la forme d'une hiérarchie de groupes. Dans une approche ascendante, chaque observation constitue initialement un groupe individuel, puis les groupes les plus proches sont progressivement fusionnés. Les résultats peuvent être représentés à l'aide d'un dendrogramme, qui permet de visualiser les différentes étapes de regroupement.

Finalement, les méthodes fondées sur la densité cherchent à identifier des zones dans lesquelles les observations sont particulièrement concentrées. DBSCAN (Density-Based Spatial Clustering of Applications with Noise) est un exemple de cette famille. Il permet notamment d'identifier des groupes de formes variées et de distinguer les observations considérées comme du bruit.

Ces différentes approches reposent sur des principes distincts et présentent chacune des avantages et des limites selon la structure des données étudiées.

2.3. C. La place de l'Affinity Propagation

L'algorithme Affinity Propagation, proposé par Brendan J. Frey et Delbert Dueck en 2007 [1], constitue une approche particulière du clustering.

Contrairement à K-means, il ne nécessite pas de fixer directement le nombre de groupes avant l'exécution de l'algorithme. Il repose sur les similarités entre les observations et cherche à identifier des observations représentatives, appelées "exemplars", qui serviront de représentants aux différents groupes. Chaque observation est ensuite associée à l'un de ces exemplaires, ce qui permet de constituer les clusters.

Le fonctionnement de l'algorithme repose sur des échanges itératifs de messages entre les observations. Ces messages permettent progressivement de déterminer quelles observations sont les plus pertinentes pour représenter les groupes.

L'Affinity Propagation se distingue ainsi par son principe de sélection des représentants : plutôt que de construire des centres artificiels, comme dans K-means, il sélectionne des observations réellement présentes dans le jeu de données. Cette particularité constitue l'un des éléments centraux de son fonctionnement et sera étudiée plus en détail dans les parties suivantes.

Bibliographie

[1] Brendan J. Frey et Delbert Dueck. « Clustering by Passing Messages Between Data Points ». In : *Science* 315.5814 (2007), p. 972-976. doi : 10.1126/science.1136800.